

BẢO VỆ LUẬN VĂN TỐT NGHIỆP

Khung AI Pháp Y Kết Hợp Để Phát Hiện Các Tài Liệu Kiểm Tra Bị Giả Mạo

A Hybrid Forensic AI Framework for Detecting Tampered Examination Documents Using OCR, Layout Analysis and Semantic Similarity

Sinh viên thực hiện: Hoàng Văn Nam (11236160)

Giảng viên hướng dẫn: TS. Phạm Minh Hoàn

Đơn vị: Khoa Công nghệ thông tin - Trường ĐH Kinh Tế Quốc Dân

Nội dung trình bày

01 Vấn đề thực tiễn & Khoảng trống nghiên cứu

02 Câu hỏi nghiên cứu & Mục tiêu

03 Bộ dữ liệu VEDTD

04 Kiến trúc hệ thống (4 Module)

05 Kết quả thực nghiệm

06 Phân tích sâu & So sánh

07 Nhận xét, hạn chế & Hướng phát triển

1. Vấn đề thực tiễn

Tài liệu giáo dục, pháp lý (đề thi, bảng điểm, hợp đồng) được số hóa mang lại nhiều tiện ích nhưng cũng tạo ra kẽ hở lớn cho các hành vi giả mạo tinh vi, khó phát hiện bằng mắt thường.

4 Hành vi giả mạo phổ biến:

Loại A

Chèn nội dung (Insert)

Chèn thêm đoạn văn bản, điều khoản mới vào tài liệu gốc.

Loại B

Xóa nội dung (Delete)

Xóa bớt dữ kiện, điều khoản quan trọng của tài liệu gốc.

Loại C

Thay đổi từ khóa (Modify)

Chỉnh sửa các từ ngữ then chốt làm đảo ngược ý nghĩa (VD: đổi "và" thành "hoặc").

Loại D

Thay đổi bố cục (Layout)

Giữ nguyên nội dung chữ nhưng thay đổi font, căn lề, giãn dòng để che giấu vết chỉnh sửa.

1. Khoảng trống nghiên cứu

Các phương pháp hiện tại chỉ giải quyết được một phần của bài toán, dẫn đến các điểm mù (blind spots) nghiêm trọng khi đối mặt với các thủ đoạn giả mạo tinh vi.

Phương pháp hiện tại	Điểm mạnh	Điểm yếu (Khoảng trống)
Document Forensics (Pháp y tài liệu truyền thống)	Phát hiện tốt dấu vết trên ảnh (copy-move, splicing).	Không hiểu được nội dung văn bản.
OCR Verification	So sánh trực tiếp nội dung văn bản.	Dễ nhầm lẫn OCR với giả mạo thật, bỏ qua yếu tố bố cục.
Semantic Similarity (SBERT, PhoBERT)	Phát hiện sự thay đổi về mặt ý nghĩa.	Bỏ qua hoàn toàn yếu tố cấu trúc, bố cục trang.
LayoutLMv3	Biểu diễn tốt cấu trúc không gian đa phương thức.	Chưa được khai thác chuyên sâu cho bài toán Tampering Detection.

Giải pháp đề xuất: Cần một Framework lai (Hybrid) kết hợp đồng thời cả 3 nguồn đặc trưng.

2. Câu hỏi nghiên cứu & Mục tiêu

Câu hỏi nghiên cứu (RQs)

RQ1: Phương pháp so khớp dựa trên OCR đơn thuần có đủ để phát hiện tài liệu bị chỉnh sửa hay không?

RQ2: Việc kết hợp đặc trưng Bố cục (Layout) và Ngữ nghĩa (Semantic) có cải thiện kết quả phát hiện?

RQ3: Trong 4 loại chỉnh sửa (Insert, Delete, Modify, Layout), loại nào khó phát hiện nhất và vì sao?

Mục tiêu đề tài

- Xây dựng bộ dữ liệu VEDTD** (Vietnamese Examination Document Tampering Dataset) có kiểm soát phục vụ đánh giá.
- Đề xuất Hybrid Forensic AI Framework** dựa trên OCR, Layout Analysis (LayoutLMv3) và Semantic Similarity (PhoBERT).
- Xây dựng hệ thống hoàn chỉnh** bao gồm mô đun phát hiện (Detector) và mô đun giải thích (Explainer) mức độ dòng.

3. Bộ dữ liệu VEDTD

Vietnamese Examination Document Tampering Dataset: Bộ dữ liệu giả mạo có kiểm soát do đề tài tự xây dựng.

Thông tin thu thập

- Nguồn:** Luật dân sự, Luật hình sự, Slide môn học, Quy chế đào tạo, Công văn.
- Quy mô thực nghiệm:** ~298 tài liệu gốc.
- Tổng quy mô xử lý:** ~1.490 tài liệu (bao gồm cả bản gốc và các bản bị tấn công).

Cấu trúc 5 nhóm nhãn

Nhãn	Mô tả cách sinh dữ liệu
1. Original	Tài liệu chuẩn (Ground truth).
2. Insert	Chèn đoạn văn mới (VD: 9 dòng).
3. Delete	Xóa đoạn văn (VD: 3 dòng).
4. Modify	Đổi từ khóa (VD: "và" thành "hoặc").
5. Layout	Đổi font, căn lề, giãn dòng.

4. Kiến trúc hệ thống - Tổng quan

Pipeline gồm 4 Module chính, xử lý từ dữ liệu thô đến phân loại và giải thích.

Đầu vào: File PDF (Bản gốc & Bản nghi ngờ)

PyMuPDF (Render thành ảnh) → PaddleOCR (Trích xuất Text + BBox)



Tầng Explainer: Xác định chính xác dòng bị lỗi & Vẽ Highlight báo cáo

4.1. Module OCR (Trích xuất & So khớp)

Công nghệ: PaddleOCR

- Được lựa chọn vì khả năng hỗ trợ tiếng Việt xuất sắc.
- Độ chính xác cao, mã nguồn mở.

Dữ liệu trích xuất

- Nội dung văn bản (Text).
- Tọa độ không gian (Bounding box) làm đầu vào cho LayoutLMv3.
- Độ tin cậy (Confidence score).

Đặc trưng trích xuất (Features)

Module đối chiếu kết quả OCR của tài liệu nghi ngờ với văn bản chuẩn (ground truth) để tính toán:

- **CER (Character Error Rate):** Tỷ lệ lỗi cấp độ ký tự.
- **WER (Word Error Rate):** Tỷ lệ lỗi cấp độ từ.

** Kỳ vọng: CER/WER sẽ tăng mạnh ở các hành vi Insert, Delete và Modify.*

4.2. Module Semantic (Ngữ nghĩa)

Công nghệ: PhoBERT

- Mô hình ngôn ngữ tiền huấn luyện trên 20GB ngữ liệu tiếng Việt.
- Xử lý tốt đặc thù ranh giới từ (word-level) của tiếng Việt.

Quy trình xử lý

1. Chia nhỏ văn bản thành các đoạn (chunk) ~200 từ.
2. Đưa qua PhoBERT để lấy Vector Embedding.
3. Tính Cosine Similarity giữa tài liệu gốc và nghi ngờ.

Đặc trưng trích xuất (5 Features)

Đo lường sự tương đồng theo cả 2 chiều:

- **Mean Similarity** (Trung bình toàn tài liệu).
- **Min Similarity** (Đoạn khác biệt nhất).
- **Std Similarity** (Độ lệch chuẩn).
- **Ref → Hyp Mean**: Từ gốc sang nghi ngờ.
- **Hyp → Ref Mean**: Từ nghi ngờ sang gốc.

4.3. Module Layout (Phân tích Bố cục)

Công nghệ: LayoutLMv3

- Mô hình Transformer đa phương thức tiên tiến.
- Kết hợp đồng thời 3 luồng thông tin: Text, Ảnh tài liệu, và Tọa độ (Bbox).
- Vượt trội so với các đặc trưng hình học thủ công (khoảng cách dòng, mật độ chữ).

Quy trình & Đặc trưng

- Chuẩn hóa Bbox về thang đo 0-1000.
- LayoutLMv3 sinh vector đặc trưng (token-level).
- Gộp vector (Mean pooling) theo trang và tài liệu.
- Tính **Cosine Similarity** so với bản gốc.

** Đặc trưng này nhạy bén với việc đổi định dạng, và "hiệu ứng lan truyền" vị trí.*

4.4. Module Fusion (Hợp nhất & Phân loại)

Công nghệ: XGBoost

Mô hình học máy cây quyết định (Gradient Boosting) được dùng làm tầng phân loại cuối cùng.

Lý do lựa chọn:

- Hoạt động hiệu quả với tập dữ liệu vừa và nhỏ.
- Mô hình hóa tốt quan hệ phi tuyến giữa các nguồn đặc trưng khác biệt.
- Cung cấp **Feature Importance** để giải thích quyết định của mô hình.

Luồng Input / Output

Input: 8 Đặc trưng tổng hợp

- 2 đặc trưng OCR (CER, WER)
- 5 đặc trưng Semantic (PhoBERT)
- 1 đặc trưng Layout (LayoutLMv3 Cosine)

Output: Phân loại 5 lớp

Original, Insert, Delete, Modify, Layout (kèm độ tin cậy).

5. Kết quả thực nghiệm: Đặc trưng OCR

Bảng so sánh tỷ lệ lỗi ký tự (CER) và lỗi từ (WER) so với văn bản gốc chuẩn.

Nhóm tài liệu	Macro CER (%)	Macro WER (%)	Nhận xét
1. Original	14.23	55.65	(Đường cơ sở - Lỗi do hệ thống nhận dạng ảnh mờ)
2. Insert	18.53	60.81	Tăng mạnh do nội dung mới không khớp.
3. Delete	15.57	56.38	Tăng nhẹ.
4. Modify	15.07	56.93	Tăng nhẹ do đổi từ.
5. Layout	14.10	55.16	Gần như KHÔNG ĐỔI so với gốc.

→ Kết luận: Đặc trưng OCR hoàn toàn "mù" trước các cuộc tấn công thay đổi bố cục.

5. Kết quả thực nghiệm: Đặc trưng Semantic

Độ tương đồng ngữ nghĩa bằng PhoBERT (so với bản gốc).

Nhóm tấn công	Mean Similarity	Min Similarity	Ref → Hyp Mean
1. Original	0.8289	0.6397	0.8823
2. Insert	0.8279	0.6271	0.8800
3. Delete	0.8293	0.6306	0.8801
4. Modify	0.8258	0.6353	0.8793
5. Layout	0.8277	0.6380	0.8819

Nhận xét: Tín hiệu rất bằng phẳng (chênh lệch ~0.003).

Nguyên nhân do kích thước phân đoạn (chunking 200 từ) quá lớn và việc lấy trung bình (mean pooling) đã làm "pha loãng" các thay đổi cục bộ của vài từ ngữ.

5. Kết quả thực nghiệm: Đặc trưng Layout

Độ tương đồng Cosine của vector không gian (LayoutLMv3 embedding).

Nhóm tấn công	Mean Cosine Similarity	Std Dev	Min Similarity
1. Original	(Ground truth)	-	-
4. Modify	0.9998	0.0003	0.9962
5. Layout	0.9980	0.0039	0.9561
3. Delete	0.9983	0.0068	0.9200
2. Insert	0.9961	0.0080	0.9313

→ LayoutLMv3 cực kỳ nhạy cảm! Không chỉ phát hiện Layout Attack mà còn phản ứng rất mạnh với Insert/Delete (Min Similarity giảm sâu).


5. Hiệu năng mô hình kết hợp (Hybrid Fusion)

ACCURACY TỔNG THỂ: 70.81%

Nhóm (Class)	Precision	Recall	F1-Score	Nhận xét
1. Original	0.97	0.98	0.98	Nhận diện xuất sắc
5. Layout	0.73	0.75	0.74	Phân loại khá tốt
2. Insert	0.63	0.75	0.68	Có sự nhầm lẫn
3. Delete	0.54	0.42	0.47	Nhầm lẫn cao với Modify
4. Modify	0.64	0.65	0.64	Khó phát hiện rõ rệt

6. Mức độ đóng góp của đặc trưng (Feature Importance)

Đánh giá của thuật toán XGBoost về tầm quan trọng của 8 đặc trưng đầu vào.



Đặc trưng Layout áp đảo hoàn toàn, trong khi 5 đặc trưng Semantic (tổng ~32%) đóng góp yếu nhất.

6. Giải mã nhầm lẫn: Hiệu ứng lan truyền vị trí

Tại sao Insert/Delete bị nhầm thành Layout?

Dữ liệu Confusion Matrix cho thấy nhiều mẫu Insert, Delete, Modify bị hệ thống gán nhãn sai thành **5.Layout**.

Nguyên nhân gốc rễ: Positional Shift Effect.

- Khi **chèn (Insert)** hoặc **xóa (Delete)** một vài dòng, toàn bộ các dòng văn bản phía sau trên trang sẽ bị đẩy xuống hoặc kéo lên.
- Sự dịch chuyển vật lý này làm thay đổi tọa độ Bbox của hàng chục dòng khác.

Hậu quả đối với Mô hình

Vì LayoutLMv3 tính embedding gộp toàn trang (mean pooling), độ lệch Layout sinh ra do việc đẩy dòng lớn hơn nhiều so với độ lệch OCR cục bộ tại dòng bị chèn/xóa.

Kết hợp với việc Layout có **Feature Importance = 44.9%**, mô hình bị thiên vị và quyết định đây là một cuộc tấn công "Thay đổi bố cục" thay vì chèn nội dung.

6. Thực nghiệm trên tài liệu thật (Case Study)


Thử nghiệm trên văn bản Luật 01-2021-QH15 (quy mô 800 dòng văn bản).

Loại tấn công thực tế	Mô đun Explainer (Khoanh vùng dòng)	Mô đun Fusion (Dự đoán tài liệu)	Xác suất chi tiết
Insert (Chèn 9 dòng)	✓ Phát hiện đúng 100% (9/9 dòng)	✗ Sai (Layout)	Layout: 81.59% Insert: 1.01%
Delete (Xóa 3 dòng)	✓ Phát hiện đúng 100% (3/3 dòng)	✗ Sai (Layout)	Layout: 96.44% Delete: 2.43%
Modify (Đổi "và" → "hoặc")	✓ Bắt được CER dòng 21-24%	✗ Sai (Layout)	Layout: 96.99% Modify: 0.11%

Mô đun Explainer (Line-level) hoạt động cực kỳ chính xác.
Mô đun phân loại tổng (Doc-level) bị thiên vị Layout do hiệu ứng lan truyền.

6. So sánh với các phương pháp Baseline

So sánh độ chính xác (Accuracy 5-class) của kiến trúc Hybrid với các phương pháp đơn lẻ.



Việc kết hợp 3 nhánh đặc trưng mang lại hiệu quả vượt trội so với sử dụng đơn lẻ.

7. Trả lời Câu hỏi nghiên cứu

RQ1: OCR-based matching có đủ để phát hiện?

KHÔNG. OCR hoàn toàn "mù" trước các cuộc tấn công bố cục (Layout Attack) vì nội dung văn bản không thay đổi.

RQ2: Kết hợp Layout + Semantic có cải thiện kết quả?

CÓ. Tăng độ chính xác tổng thể lên 69.13%. Trong đó, đặc trưng Layout đóng vai trò chi phối quyết định (44.9% Feature Importance).

RQ3: Loại chỉnh sửa nào khó phát hiện nhất?

MODIFY (Thay đổi từ khóa) và phân biệt giữa Insert/Delete với Layout. Lý do là hiệu ứng lan truyền vị trí (Positional Shift) gây nhiễu cho mô hình phân loại mức tài liệu.

7. Hạn chế & Hướng phát triển

Những hạn chế hiện tại

- **Vấn đề gộp cụm (Mean-pooling):** Làm lu mờ tín hiệu cục bộ, dẫn đến nhầm lẫn Insert/Delete/Modify thành Layout.
- **Độ hạt Semantic thô:** Chunk size 200 từ của PhoBERT quá lớn để bắt lỗi sửa 1-2 từ.
- **Quy mô dữ liệu:** 298 tài liệu/nhóm vẫn còn khiêm tốn so với thiết kế ban đầu (500/nhóm).

Hướng phát triển

- **Đặc trưng cục bộ:** Trích xuất Layout Features ở cấp độ dòng (Line-level) + thêm đặc trưng "position-shift count".
- **Kiến trúc 2 tầng:** Tầng 1 (Gốc/Đã chỉnh sửa) → Tầng 2 (Loại chỉnh sửa cụ thể).
- **Tối ưu Semantic:** Áp dụng Sliding Window hoặc nâng cấp sang BGE-M3.

Mở rộng ứng dụng: Dự án CO-Guard

Tái sử dụng Hybrid Framework để phát hiện gian lận trên Giấy chứng nhận xuất xứ hàng hóa (Certificate of Origin).

Trân trọng cảm ơn!

Hội đồng đã lắng nghe phần trình bày.

Tóm tắt đóng góp chính

- Xây dựng VEDTD - bộ dữ liệu giả mạo có kiểm soát tiếng Việt.
- Đề xuất thành công Framework Hybrid kết hợp OCR, Layout và Semantic.
- Xây dựng công cụ Explainer chỉ ra chính xác vị trí dòng bị can thiệp.
- Khám phá và giải thích hiện tượng "Positional Shift Effect" trong tài liệu số.

Sinh viên sẵn sàng lắng nghe và trả lời câu hỏi từ Hội đồng.